

# Caracterización de los Datos Crudos (Fuente: SIVIGILA)

**Asignatura:** ETL

**Estudiante:** Wilson Andrés Gómez Gutiérrez

Los datos crudos empleados en este pipeline provienen del Sistema de Vigilancia en Salud Pública (SIVIGILA) del Instituto Nacional de Salud. Consisten en bases de datos tabulares estructuradas (formato origen .xlsx), donde cada registro (fila) representa la notificación de un paciente individual para un evento epidemiológico específico.

Dada la naturaleza estandarizada del sistema, todas las bases de los diferentes eventos (más de 100) comparten una arquitectura base compuesta por variables universales (caras a la notificación rutinaria), diferenciándose únicamente en el último segmento de columnas, el cual captura las particularidades clínicas de cada enfermedad.

La estructura de los datos crudos se divide en cinco bloques fundamentales:

## 1. Bloque de Identificación y Datos Sociodemográficos (Variables Universales)

- **Contenido:** Variables como pri\_nom\_, pri\_ape\_, tip\_ide\_, num\_ide\_, edad\_, sexo\_, estrato\_, tip\_ss\_ (tipo de seguridad social) y grupos poblacionales especiales (gestantes, indígenas, desplazados).
- **Naturaleza:** Contiene Información Personal Identificable (PII). Son datos categóricos y numéricos enteros.
- **Condición en crudo:** Presentan un alto riesgo ético y de privacidad, por lo que requieren un proceso estricto de anonimización (eliminación de nombres, documentos y direcciones exactas) durante la fase de transformación.

## 2. Bloque Geográfico y Espacial (Variables Universales)

- **Contenido:** cod\_dpto\_o (Código DANE del departamento de ocurrencia), cod\_mun\_o (Código DANE del municipio), area\_ (cabecera municipal, centro poblado, rural disperso).
- **Naturaleza:** Variables categóricas codificadas.
- **Condición en crudo:** Son el eje transversal para la interoperabilidad futura con las proyecciones poblacionales del DANE. En crudo, abarcan todo el territorio nacional, por lo que requieren filtrado espacial (ej. cod\_dpto\_o == 73 para restringir el análisis al nivel departamental objetivo).

## 3. Bloque Epidemiológico Temporal (Variables Universales)

- **Contenido:** fec\_not (Fecha de notificación), semana (Semana epidemiológica), año, ini\_sin\_ (Fecha de inicio de síntomas), fec\_con\_ (Fecha de consulta).
- **Naturaleza:** Fechas (frecuentemente capturadas como cadenas de texto puro o *strings* en el Excel) y variables temporales discretas.
- **Condición en crudo:** Presentan inconsistencias de formato (DD/MM/YYYY vs MM/DD/YYYY) y valores nulos. Requieren conversión obligatoria a formato *datetime* para habilitar el posterior análisis de series de tiempo.

#### 4. Bloque Clínico General (Variables Universales)

- **Contenido:** tip\_cas\_ (Tipo de caso: sospechoso, confirmado por laboratorio, confirmado por clínica), pac\_hos\_ (Hospitalizado), con\_fin\_ (Condición final: vivo, muerto).
- **Naturaleza:** Variables categóricas, usualmente codificadas con números enteros (1: Sí, 2: No).

#### 5. Bloque Específico del Evento (Variables Particulares)

- **Contenido:** Corresponde a las últimas columnas de la matriz. Varía drásticamente según el protocolo de cada evento.
- **Ejemplo en crudo (Evento 813 - Tuberculosis):** Incluye variables clínicas exactas de la patología como cond\_tuber (Condición del ingreso), tip\_tub (Tipo de tuberculosis), vih\_confirmado, peso\_act, talla\_act, imc, baciloscop y resultados de cultivos.
- **Condición en crudo:** Es el bloque con mayor densidad de valores nulos (NaN), ya que muchas pruebas de laboratorio confirmatorias tardan semanas en procesarse y la base se extrae antes de su actualización, o los campos no aplican para todos los pacientes.

#### Problemas detectados en los datos crudos:

1. Nombres de columnas inconsistentes (mezcla de mayúsculas, minúsculas y espacios finales ocultos).
2. Ausencia de estandarización en valores nulos (celdas vacías frente a registros marcados con "NA" o "Desconocido").
3. Imputación manual errónea de edades o fechas atípicas originadas desde la Unidad Primaria Generadora de Datos (UPGD).