

Estado del arte

Asignatura: ETL

Estudiante: Wilson Andrés Gómez Gutiérrez

Antecedentes internacionales

En la última década, la vigilancia epidemiológica ha incorporado progresivamente herramientas de automatización y analítica de datos con el propósito de mejorar la oportunidad, calidad y utilidad de la información para la toma de decisiones. Este cambio responde, en gran medida, a las limitaciones de los esquemas tradicionales de consolidación manual, en los que los datos suelen llegar desde múltiples fuentes, con estructuras heterogéneas y diferentes niveles de calidad. En ese escenario, la automatización de procesos de extracción, transformación y carga se ha convertido en una estrategia relevante para integrar la información, reducir tiempos operativos y favorecer análisis más consistentes.

La literatura internacional muestra que los flujos ETL han ganado importancia en salud pública porque permiten organizar procesos repetitivos de lectura, validación, estandarización y almacenamiento de datos. Este tipo de arquitecturas no solo mejora la trazabilidad del procesamiento, sino que facilita la reproducibilidad y el monitoreo continuo de las tareas. En varios trabajos recientes, herramientas de orquestación han sido utilizadas como una alternativa útil para estructurar flujos de trabajo programados, establecer dependencias entre tareas y mantener una lógica ordenada en el procesamiento de información sanitaria. No obstante, más allá de la herramienta concreta, el valor real de estos enfoques radica en la posibilidad de construir procesos confiables y sostenibles para transformar datos dispersos en insumos analíticos útiles.

De forma paralela, la analítica predictiva ha tomado un papel cada vez más visible en la vigilancia epidemiológica. Distintos estudios han explorado el uso de modelos estadísticos y de aprendizaje automático para identificar patrones temporales, detectar anomalías y anticipar comportamientos inusuales en ciertos eventos en salud. Entre los enfoques más reportados se encuentran Random Forest, XGBoost, regresión logística, ARIMA, Prophet y LSTM, todos ellos aplicados en distintos contextos de predicción y clasificación. Sin embargo, una lectura más prudente de la literatura sugiere que no existe un modelo universalmente superior; su desempeño depende del tipo de evento analizado, la calidad de los datos, la periodicidad de los registros y la forma en que se construyen las variables de entrada.

Otro hallazgo relevante en los antecedentes internacionales es que los mejores resultados predictivos suelen estar estrechamente relacionados con la calidad del procesamiento previo. Es decir, el comportamiento del modelo depende tanto del algoritmo como de la depuración, homologación y estructuración de la base que lo

alimenta. En consecuencia, la literatura más sólida no plantea la inteligencia artificial como una solución aislada, sino como parte de una cadena de valor del dato en la que primero se requiere integrar fuentes, corregir inconsistencias y consolidar series históricas comparables. Esta idea es importante porque desplaza el énfasis desde la sofisticación del algoritmo hacia la robustez del pipeline que hace posible el análisis.

También se observan experiencias internacionales en las que la automatización de la vigilancia se articula con varias capas de información, como registros clínicos, vigilancia sindrómica, eventos reportados digitalmente y sistemas de alerta temprana. Más allá de los casos puntuales, lo que muestran estas referencias es que los sistemas más maduros no dependen solo de recolectar más datos, sino de articular flujos consistentes que permitan una lectura oportuna del comportamiento epidemiológico.

Contexto colombiano

En Colombia, la vigilancia en salud pública ha avanzado de forma importante en términos de digitalización, disponibilidad de registros y acceso a microdatos. El sistema SIVIGILA constituye la principal fuente de notificación de eventos de interés en salud pública y representa un soporte clave para el monitoreo epidemiológico. La disponibilidad de microdatos históricos para consulta e investigación constituye una base favorable para el desarrollo de procesos analíticos más complejos.

A pesar de estos avances, persisten desafíos importantes en materia de integración de fuentes. Uno de los más relevantes es la articulación entre los datos de casos reportados en SIVIGILA y los denominadores poblacionales requeridos para construir tasas e indicadores comparables. Esta dificultad no es menor, porque limita la capacidad de pasar de una lectura descriptiva del número de casos a una interpretación territorial del riesgo, especialmente cuando se requiere desagregar por municipio, grupo etario o sexo.

En el caso del Tolima, esta necesidad adquiere mayor sentido por la diversidad territorial y el comportamiento diferencial de varios eventos epidemiológicos. Actualmente, buena parte de la información debe cruzarse de forma manual mediante archivos Excel, correos y procesos repetitivos de depuración, lo que consume tiempo técnico y aumenta el riesgo de error. Además, esta forma de trabajo impide consolidar una base histórica integrada y retrasa la interpretación oportuna de los eventos, particularmente en escenarios emergentes donde se requieren respuestas rápidas.

Desde esta perspectiva, el contexto colombiano no muestra una ausencia total de información, sino una brecha entre disponibilidad de datos y capacidad efectiva de integrarlos, depurarlos y transformarlos en inteligencia útil para la gestión. Esa brecha es precisamente la que justifica proyectos orientados a automatizar el procesamiento y a fortalecer el uso analítico de la vigilancia epidemiológica en escalas subnacionales.

Brecha de investigación

Al revisar el panorama actual, se observa que una parte importante del estado del arte se concentra en describir tecnologías, modelos y arquitecturas avanzadas. Aunque estas referencias son valiosas para mostrar el panorama general, no todas responden de manera directa a la necesidad concreta del proyecto. En un trabajo de grado como este, la brecha no está en demostrar cuál es la tecnología más sofisticada, sino en evidenciar que sigue existiendo una distancia entre los sistemas de información disponibles y su aprovechamiento analítico real en un contexto territorial específico.

La principal brecha identificada puede formularse así: aunque existen múltiples estudios sobre modelos predictivos aplicados a salud pública y diversas experiencias de automatización de datos, son menos frecuentes los trabajos que documenten de manera integral la construcción de un pipeline reproducible, orientado a un contexto subnacional y diseñado para resolver problemas operativos reales de vigilancia. En otras palabras, existe literatura sobre predicción y también sobre herramientas de ingeniería de datos, pero son menos comunes los desarrollos aplicados que conecten ambas dimensiones de manera útil para una entidad territorial.

En este caso, esa brecha se hace más evidente por tres razones. La primera es que el procesamiento actual sigue dependiendo de una lógica manual y fragmentada, lo que limita la oportunidad del análisis. La segunda es que la integración entre SIVIGILA y DANE no está resuelta de manera automatizada, pese a que esa unión es necesaria para construir tasas e indicadores robustos. La tercera es que, sin una base histórica consolidada y normalizada, cualquier intento de modelado predictivo queda condicionado por problemas previos de calidad del dato.

Por ello, la brecha de investigación no debe presentarse solamente como la falta de aplicación de inteligencia artificial, sino como la necesidad de construir una base metodológica y técnica que permita pasar de datos dispersos a información estructurada, comparable y aprovechable analíticamente. Esta formulación resulta más sólida y más coherente con las necesidades reales del problema planteado.

Aporte esperado del proyecto

A partir de la revisión realizada, el aporte del proyecto puede entenderse en dos niveles complementarios. En primer lugar, plantea una contribución técnica, al proponer el diseño de un pipeline ETL que automatice la extracción, transformación y consolidación de datos epidemiológicos y poblacionales. Esto permitiría reducir la dependencia de procesos manuales, mejorar la trazabilidad de la información y construir una base histórica más estable para el análisis.

En segundo lugar, el proyecto tiene un aporte aplicado en salud pública, porque esa automatización no se plantea como un fin en sí mismo, sino como una condición para fortalecer la vigilancia epidemiológica en el Tolima. Al integrar los registros de

casos con denominadores poblacionales y estructurarlos por unidades territoriales comparables, se facilitaría la construcción de indicadores más oportunos y útiles para interpretar el comportamiento de los eventos. Sobre esa base, sería viable avanzar hacia modelos estadísticos o predictivos orientados a identificar incrementos inusuales, patrones temporales o territorios con mayor riesgo.

En ese sentido, el proyecto no promete una solución total ni una superioridad automática de ciertos algoritmos; propone una contribución progresiva y realista: organizar el dato, hacerlo interoperable y dejar una base sólida para analítica más avanzada. Su valor no radica solamente en incorporar tecnología, sino en adaptarla a una problemática real de gestión de información en salud pública.

En síntesis, el proyecto es pertinente porque responde a una necesidad concreta de la vigilancia epidemiológica territorial: transformar procesos manuales y dispersos en un flujo reproducible de integración de datos que mejore la oportunidad del análisis y abra la puerta a herramientas predictivas mejor fundamentadas. A partir de lo anterior, se justifica el desarrollo de un pipeline automatizado para la integración de datos epidemiológicos y poblacionales en el Tolima, no solo como una mejora operativa en el procesamiento de la información, sino como una base necesaria para avanzar hacia análisis estadísticos y modelos predictivos que aporten a una vigilancia más oportuna, comparable y territorialmente útil.

Referencias

Fuentes citadas

1. Artificial intelligence-enabled public health surveillance—from local detection to global epidemic monitoring and control | Request PDF - ResearchGate, acceso: marzo 18, 2026, https://www.researchgate.net/publication/344837794_Artificial_intelligence-enabled_public_health_surveillance-from_local_detection_to_global_epidemic_monitoring_and_control
2. (PDF) Enhancing Digital Disease Surveillance in Thailand Using Information Technology, Data Engineering, Data Science, and Artificial Intelligence - ResearchGate, acceso: marzo 18, 2026, https://www.researchgate.net/publication/390324641_Enhancing_Digital_Disease_Surveillance_in_Thailand_Using_Information_Technology_Data_Engineering_Data_Science_and_Artificial_Intelligence
3. ETL Workflow Automation with Apache Airflow - DataTerrain, acceso: marzo 18, 2026, <https://dataterrain.com/etl-workflow-automation-apache-airflow>
4. Apache Airflow: Architecture and Life Science Workflows - IntuitionLabs.ai, acceso: marzo 18, 2026, <https://intuitionlabs.ai/articles/airflow-life-science-workflows>
5. Automating Healthcare Triage with Airflow and Large Language ..., acceso: marzo 18, 2026, <https://airflowsummit.org/sessions/2025/automating-healthcare/>

6. State of Airflow 2026: The Orchestration Layer is Uniting Data, AI, and Enterprise Growth, acceso: marzo 18, 2026, <https://www.astronomer.io/blog/state-of-airflow-2026/>
7. Digital Disease Surveillance - odess.io, acceso: marzo 18, 2026, <https://www.odess.io/en/initiative/digital-disease-surveillance/>
8. Documentation | Apache Airflow, acceso: marzo 18, 2026, <https://airflow.apache.org/docs/>
9. Comparative analysis of CatBoost, LightGBM, XGBoost, RF, and DT methods optimised with PSO to estimate the number of k-barriers for intrusion detection in wireless sensor networks, acceso: marzo 18, 2026, <https://d-nb.info/1371106908/34>
10. (PDF) A Comparative Evaluation of Random Forest and XGBoost Models for Disease Detection Using Medical Indicators - ResearchGate, acceso: marzo 18, 2026, https://www.researchgate.net/publication/388091937_A_Comparative_Evaluation_of_Random_Forest_and_XGBoost_Models_for_Disease_Detection_Using_Medical_Indicators
11. Comparative Study of Arima, Lstm and Prophet Models for Time Series Forecasting: A Comprehensive Review - Preprints.org, acceso: marzo 18, 2026, <https://www.preprints.org/manuscript/202601.1377/v1/download>
12. Performance Analysis of Boosting Classifiers in Recognizing Activities of Daily Living - MDPI, acceso: marzo 18, 2026, <https://www.mdpi.com/1660-4601/17/3/1082>
13. Comparative Evaluation of Logistic Regression and ... - medRxiv.org, acceso: marzo 18, 2026, <https://www.medrxiv.org/content/10.64898/2026.03.05.26347655v1.full.pdf>
14. Performance Analysis of Boosting Classifiers in Recognizing Activities of Daily Living, acceso: marzo 18, 2026, https://www.researchgate.net/publication/339157430_Performance_Analysis_of_Boosting_Classifiers_in_Recognizing_Activities_of_Daily_Living
15. Mathematical Analysis and Prediction of Future Outbreak of Dengue on Time-varying Contact Rate using Machine Learning Approach | Request PDF - ResearchGate, acceso: marzo 18, 2026, https://www.researchgate.net/publication/381207435_Mathematical_Analysis_and_Prediction_of_Future_Outbreak_of_Dengue_on_Time-varying_Contact_Rate_using_Machine_Learning_Approach
16. Comparative Analysis of ARIMA, SARIMA and Prophet Model in Forecasting, acceso: marzo 18, 2026, <https://www.sciencepublishinggroup.com/article/10.11648/j.rd.20240504.13>
17. 2025 Allen D. Lemman Swine Conference Research Abstracts and Proceedings September 20-23, 2025 Saint Paul, Minnesota, USA - University Digital Conservancy, acceso: marzo 18, 2026, <https://conservancy.umn.edu/bitstreams/c3e145d2-ca41-49bc-9c4c-4f814fd59cd1/download>
18. Enhancing Digital Disease Surveillance in Thailand Using Information Technology, Data Engineering, Data Science, and Artificial Intelligence -

- ThaiJO, acceso: marzo 18, 2026, <https://he02.tci-thaijo.org/index.php/OSIR/article/download/272056/186655>
19. Infectious disease prediction model based on optimized deep learning algorithm - Frontiers, acceso: marzo 18, 2026, <https://www.frontiersin.org/journals/public-health/articles/10.3389/fpubh.2025.1703506/full>
 20. Lineamientos nacionales para la vigilancia en salud pública 2025 ..., acceso: marzo 18, 2026, <https://www.ins.gov.co/BibliotecaDigital/lineamientos-vigilancia-2025.pdf>
 21. Encuesta nacional de calidad de vida (ECV) 2024 - DANE, acceso: marzo 18, 2026, <https://www.dane.gov.co/index.php/estadisticas-por-tema/salud/calidad-de-vida-ecv/encuesta-nacional-de-calidad-de-vida-ecv-2024>
 22. Colombia - Encuesta Nacional de Calidad de Vida - ECV - 2024 - DANE, acceso: marzo 18, 2026, <https://microdatos.dane.gov.co/index.php/catalog/861/pdf-documentation>
 23. The Epidemiological Impact of Dengue in Colombia: A Systematic Review - ResearchGate, acceso: marzo 18, 2026, https://www.researchgate.net/publication/385098782_The_Epidemiological_Impact_of_Dengue_in_Colombia_A_Systematic_Review
 24. Estimating the burden of disease and the economic cost attributable to chikungunya, Colombia, 2014 | Request PDF - ResearchGate, acceso: marzo 18, 2026, https://www.researchgate.net/publication/285390599_Estimating_the_burden_of_disease_and_the_economic_cost_attributable_to_chikungunya_Colombia_2014
 25. How many patients with post-chikungunya chronic inflammatory rheumatism can we expect in the new endemic areas of Latin America? | Request PDF - ResearchGate, acceso: marzo 18, 2026, https://www.researchgate.net/publication/277717054_How_many_patients_with_post-chikungunya_chronic_inflammatory_rheumatism_can_we_expect_in_the_new_endemic_areas_of_Latin_America
 26. Assessing dengue forecasting methods: a comparative study of ..., acceso: marzo 18, 2026, <https://www.springermedizin.de/assessing-dengue-forecasting-methods-a-comparative-study-of-stat/52112782>
 27. Human and animal sentinels for shared health risks - IZS, acceso: marzo 18, 2026, https://www.izs.it/vet_italiana/2009/45_1/23.pdf
 28. Proceedings of the Fourth Workshop on NLP for Positive Impact (NLP4PI) - ACL Anthology, acceso: marzo 18, 2026, <https://aclanthology.org/2025.nlp4pi-1.pdf>
 29. Human Digital Twin: Data, Models, Applications, and Challenges - ResearchGate, acceso: marzo 18, 2026, https://www.researchgate.net/publication/394539662_Human_Digital_Twin_Data_Models_Applications_and_Challenges
 30. Human Digital Twin: Data, Models, Applications, and Challenges - arXiv.org, acceso: marzo 18, 2026, <https://arxiv.org/html/2508.13138v1>

Comparison of machine learning algorithms for dengue virus (DENV) classification,
accesso: marzo 18, 2026, https://www.scielo.org.mx/scielo.php?pid=S1665-64232024000500729&script=sci_arttext